

2009 mars - Tracking

1. Lucas-Kanade

- Ganska räkneintigt
- Sub-pixel noggrannhet?
- Begränsning i "block"
- Kan inte hantera icke-differensierbara bilder

Block-matching

- Mycket räkneintigt
- ? - Enkelt att implementera
- ber inte om unik displacement
- kan hantera icke-differentierbara bilder
- Begränsning i block-storlek och längd på förflyttning

Genom att kombinera dem skulle man kunna få en relativt snabb algoritm som kan hantera icke-differentierbara bilder. Man kanske börjar med Lucas Kanade och sedan använder block-matching.

2. En symmetrisk version om A bara var en translation är $\varepsilon = \|f(x + \frac{d}{2}) - f(x - \frac{d}{2})\|$. Den generella formen blir $\varepsilon = \|f_1(A^{1/2}(x)) - f_2(A^{1/2}(x))\|$
där $A^{1/2} \cdot A^{1/2} = A$??

3. b) Regulärerad derivata:

Alltid derivatan
av en gansisk kernel

$$\frac{\partial}{\partial x} (J * g) = \frac{\partial}{\partial x} J * g = J * \underbrace{\frac{\partial}{\partial x} g}_{-\frac{x}{\sigma^2} g}$$

a) Man använder regulärerad derivata för att den alltid ger den exakta derivatan. Om man först hade faltat och sedan deriverat filtersraset hade man fått en approximation. Dessutom hade det varit mer räkneintigt.

c) Euler-Lagrange ??

4. Background modelling can be used for tracking
when you use a stationary camera, it is
fast compared to motion estimation.

Ett "mixture model" för bilden uppskattas i varje
pixel. Om en pixel antar ett värde som kraftigt
skiljer sig från modellen klassas den pixeln som
förfgrund. Mixture modellen kan tex vara en
"Mixture of Gaussians" - MoG.

5. Den rörelse som syns i bilden är inte ett
motion field utan det optiska flödet.

Trå exempel på när de skiljer sig nedan.

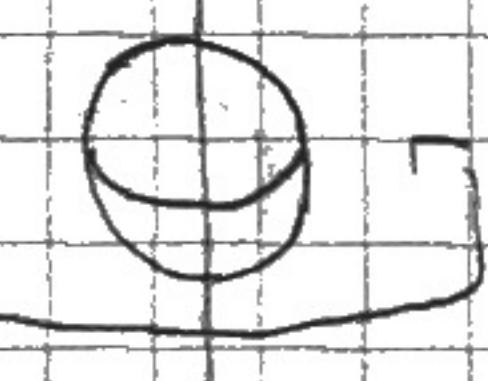
a)



Ett klot utan struktur snurrar kring
sin egen axel. Ljuskälla stilla.

Inget optiskt flöde registreras i bilden, men
i realiteten finns ett motion field åt höger på klotet.

b)



En ljuskälla rör sig runt ett
stilla stående klot.

Ett optiskt flöde åt höger på klotet registreras
i bilden men i realiteten finns inget motion field.

6. Två metoder finns:

- Least square minimization (baserad på T_{2D})

Minimerar cost function $E_{LS} = \int_{\Omega} w(x) [\nabla_{ST} f]^T \nabla_{ST} f dx$

där $\nabla_{ST} = (V_1, V_2, 1)$, $V = (V_1, V_2)$, $\nabla_{ST} f = \left(\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \frac{\partial f}{\partial t} \right)$

V_{ST} kan alltså ses som en homogen version av V .

V bestäms genom $V = T_{2D}^{-1} S$, $T = \int w(x) \nabla f(x) \nabla f(x)^T dx$

- Total least square minimization (baserad på T_{3D})

Minimerar cost-funktion $E_{TL} = \int_{\Omega} w(x) [\nabla_{ST} \nabla_{ST} f]^T \nabla_{ST} f dx$

där $\hat{V}_{ST} = (r_1, r_2, r_3)$ || \hat{V}_{ST} || = 1 $V = (V_1, V_2)$, $V_1 = \frac{r_1}{r_3}$, $V_2 = \frac{r_2}{r_3}$

V_{ST} bestäms som den egenvektor till T_{3D}
som har det minsta egenvärdet.

Certainty measure?

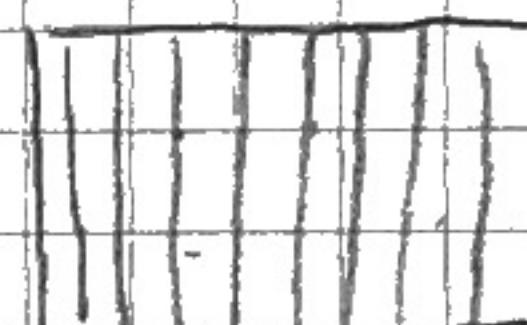
- confidence measure för 3?

- confidence measure för 4?

- control tensor för 13?

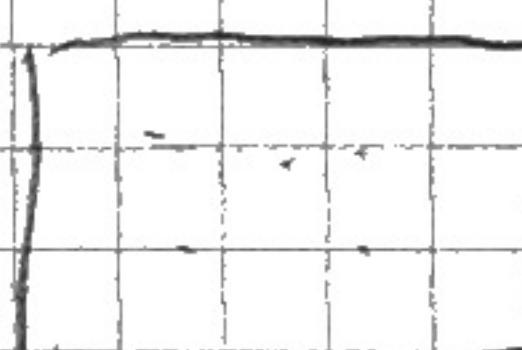
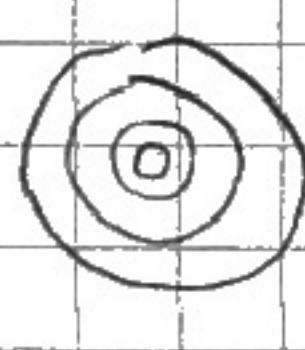
7. Den lokala informationen som ska användas är den lokala strukturen i bilden. Om man ska ta bort brus i en region med mycket struktur vill man "smootha" längs med strukturen för att bevara kanter och linjer.

Ex) Mycket struktur \rightarrow oval filter kärna \rightarrow mindre brus, bevarad



struktur

Ex) Lite struktur \rightarrow cirkulär kärna \rightarrow mindre brus



8. Om hela bilden lågpass filtreras kommer linjer, kanter och annan struktur inte att bevaras, de kommer att smetas ut och bli mindre skarpa.

Struktur tensorn T innehåller högfrekvent brus, som kommer från den brusiga bilden. Om elementen i T lågpass filtreras reduceras bruset. Den lp-filtrerade tensorn kan användas för att konstruera ett adaptivt filter till bilden.

q. a) L är en "familj" bilder $L(x,y; s) = (g_s * f)(x,y)$
där s är skala, g_s är ett gaussiskt lp-filter
 f är bilden.

D är en diffusionstensor, D beskriver μ

men i form av en 2×2 symmetrisk matris

D bestämmer formen på det adaptiva filtret

b) $\frac{d}{ds} L$ betyder förändringen i L vid (x,y)
mellan skalan s och skalan $s+\delta s$.

På så sätt definieras hur man genererar
skalnivåh $L(x,y; s+\delta s)$ från $L(x,y; s)$.

Anisotropisk diffusion upphålls genom att
itterera detta lokalt i bilden.

c) D har samma egenvektorer som T men
andra egenvärden.

d) Om T varierar långsamt m.a.p. x varierar
också D långsamt m.a.p x och högerledet
kan regulariseras enligt

$$\frac{1}{2} \operatorname{div}(D \operatorname{grad} L) \approx \frac{1}{2} \underbrace{\operatorname{tr}(D (\operatorname{dir grad} L))}_{=H}$$

där H är hessianen (andra derivatorna)

2009 mars - Stereo

10. Gissning: The epipolar constraint $y_1^T F y_2 = 0$

där $y_1 \sim C_1 X$, $y_2 \sim C_2 X$ C =kameror X = 3D-punkt

Epipolär villkoret är ett nödvändigt villkor för att ^{se} ~~de~~ ^{BBBog} y_1 och y_2 ska vara projektionen av samma punkt. Det är inte tillräckligt eftersom de fortfarande skulle kunna vara projektioner av 2 olika 3D-punkter som ligger i samma plan?

11. Geometric Invariance = robustness to view changes \Rightarrow frame equivariant to rotation, scaling and skewing

The SIFT detector finds points x, y and scales using Difference-of-Gaussians in a pyramid.

Rotation is found from a gradient histogram.

12.