

mars 2010 - Tracking

1. A mixture model of the probability of pixel intensity I

is $P(I) = \sum_{k=1}^K P(I|T_k) P(T_k)$, a popular mixture model

is mixture of Gaussians. The parameters of the mixture distribution can be calculated with the

EM (Expectation Maximisation) algorithm. The EM-algorithm:

1. Postulate mixture distribution

2. E-Step: calculate partial membership

3. M-step: estimate mixture distribution parameters

repeat 'till convergence

2. Regulariserad derivata används för att det alltid ger den exakta derivatan och för att det är mindre räkenatungt än att först fatta och sedan derivera (vilket hade givit en approximation av derivatan).

3 Se nästa sida \Rightarrow

(Ånen bilaga till LK-läbben)

3. (Igeln)

$$\epsilon(d) = \sum_x \|f(x - \frac{1}{2}d) - g(x + \frac{1}{2}d)\|^2$$

1:a ordningens Taylorutveckling ger:

$$f(x - \frac{1}{2}d) \sim f(x) - \frac{1}{2}d^T \nabla f(x)$$

$$g(x + \frac{1}{2}d) \sim g(x) + \frac{1}{2}d^T \nabla g(x)$$

$$\epsilon(d) = \sum_x \|f(x) - \frac{1}{2}d^T \nabla f(x) - g(x) - \frac{1}{2}d^T \nabla g(x)\|^2$$

Vi ska minimera med avseende på d. Beräkna

$\frac{d\epsilon}{dd} = 0$ för att hitta minimum.

$$\begin{aligned}\frac{d\epsilon}{dd} &= \sum_x 2 \|f(x) - g(x) - \frac{1}{2}d^T (\nabla f(x) + \nabla g(x))\| \cdot \frac{1}{2}(\nabla f(x) + \nabla g(x))^T \\ &= \sum_x \|f(x) - g(x)\| (\nabla f(x) + \nabla g(x)) - \sum_x d^T (\nabla f(x) + \nabla g(x)) (\nabla f(x) + \nabla g(x))^T\end{aligned}$$

$$\frac{d\epsilon}{dd} = 0 \Rightarrow \underbrace{\sum_x \|f(x) - g(x)\| (\nabla f(x) + \nabla g(x))}_{= e} = \underbrace{\sum_x (\nabla f(x) + \nabla g(x)) (\nabla f(x) + \nabla g(x))^T d}_{= T_1 + T_2}$$

\Rightarrow Symmetric UK-equation: $(T_1 + T_2)d = e$

$$(d = (T_1 + T_2)^{-1}e \quad ?)$$

mars 2010 - Motion

4

Lucas-Kanade

Block-matching

Hanterar icke-differentierbara bilder

Nej

Ja

Räkning

Nej

Ja

Sub-pixel noggrannhet

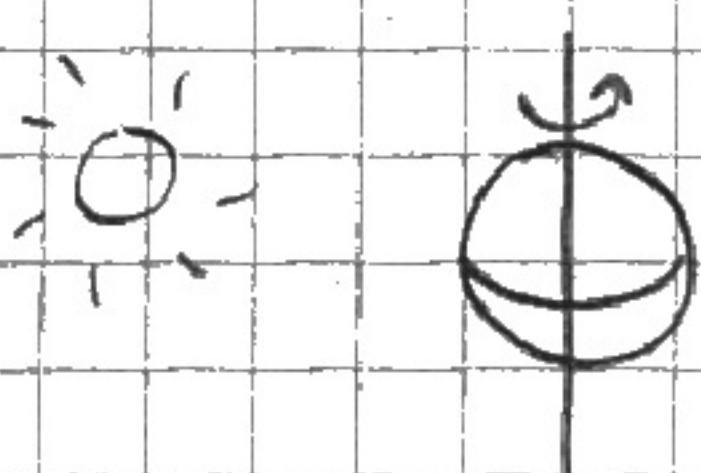
Nej ?

Ja ?

En kombination skulle kunna innebära att fört
utföra UK-tracking på hela bilden och sedan göra
block-matching för att få bättre noggrannhet eftersom
subpixel noggrannhet kan interpoleras fram. Att bara
göra block-matching skulle ta längre tid.

5. The motion field cannot be measured, what we see
in the image is the optical flow. Examples of when
they differ below:

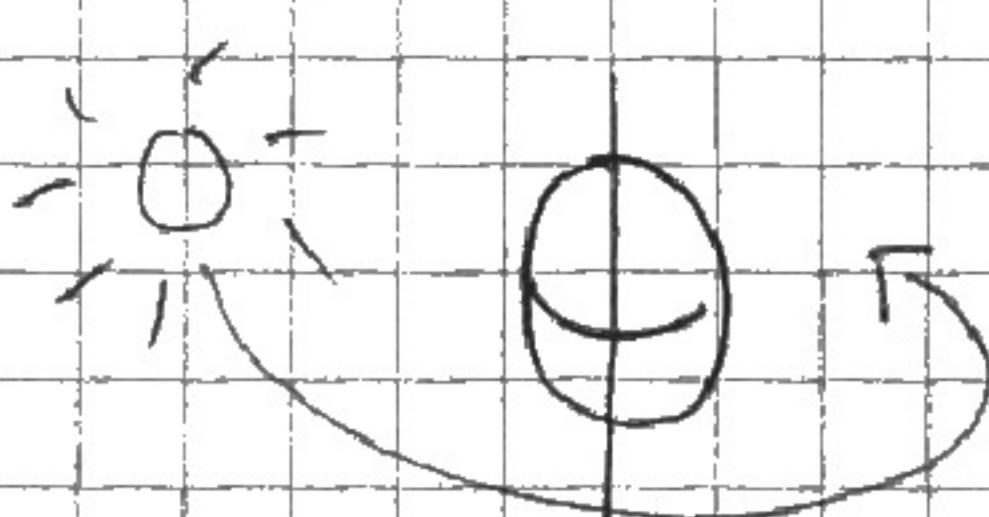
Ex 1)



Klotet snurrar alltså har vi ett motion field.

(Solen står stilla) men eftersom klotet
 saknar struktur får vi inget optical flow

Ex 2)

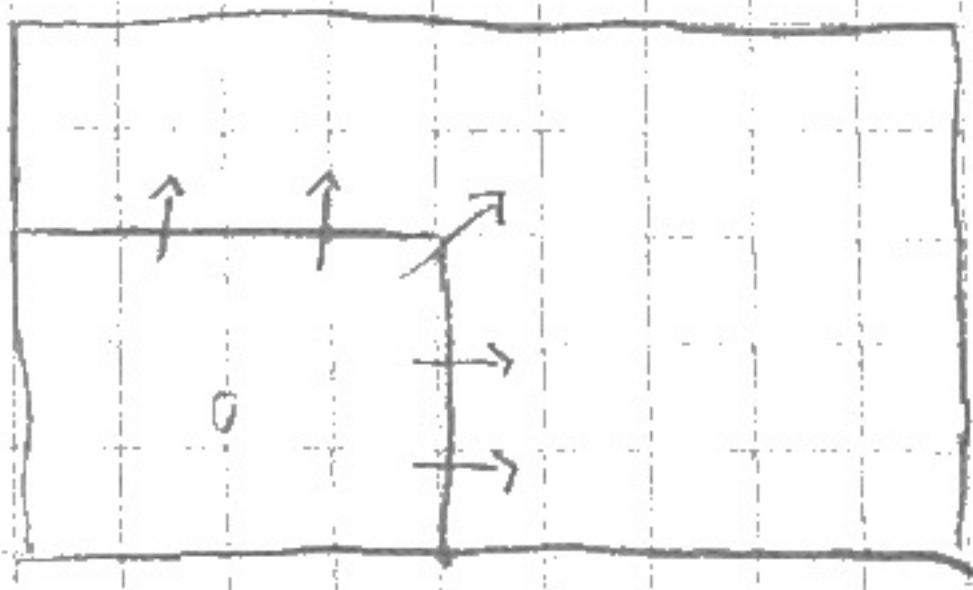


Klotet står stilla alltså har vi inget motion field

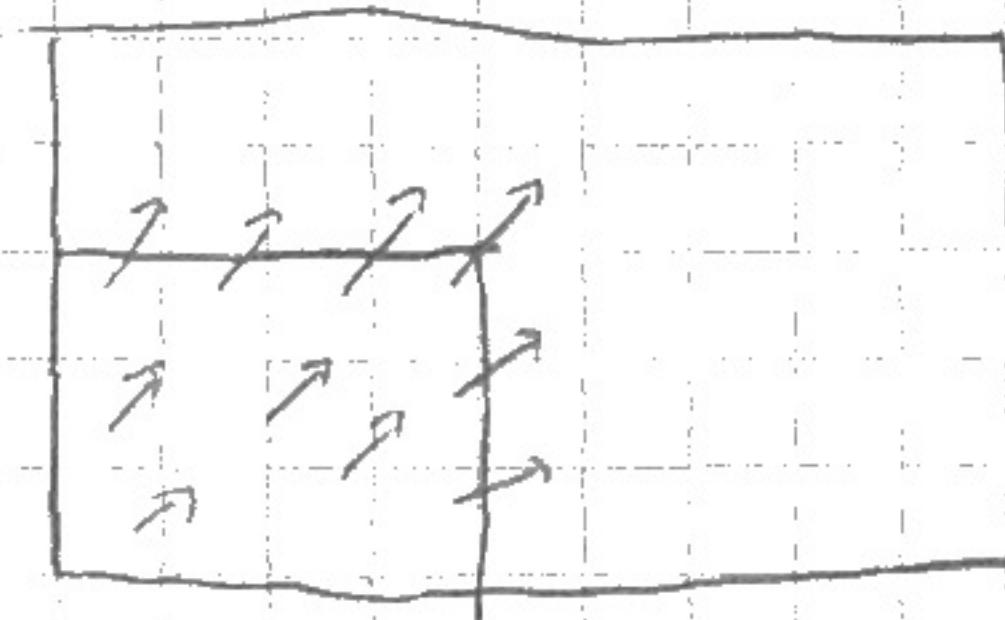
Men solen rör sig vilket ger skuggor och
därför ett optical flow.

6

Lucas-Kanade



Horn-Schunck



UK-tracking väljs alltid den kortaste vektorn i de fall där flera möjliga fall finns (tex homogena ytor och linjer/kanter). Horn-Schunk's metod tar hänsyn till närliggande pixlar och i de fall när flera möjliga rörelser finns så väljs den vektor som är mest lik resten av motion fieldet
(Kortaste vektorn är 0 i homogena ytor än den raka normalvektorn i 1D regioner)

Mars 2010 - Denoising

7. Anisotropic diffusion - tensor driven

$$g_x = g_{lp} + \sum_{k=1}^K c_k g_{hp}$$

Filtret kärnan är generellt elliptisk

men beror av den lokala strukturen i bilden.

lp-delen är samma över hela bilden men hp-delen har olika styrka för att bevara struktur i bilden.

c_k är en pixelberoende konstant.

Mjökt struktur Lite struktur

8. Controltensorn $C(x)$ är baserad på en lp-filtrerad

version av struktur tensorn. De har samma

egenvektorer men olika egenvärden för en

2D-bild behövs 3 hp-filtar och 1 lp-filtar totalt

$$(g_x = g_{lp} + \sum_{k=1}^K c_k g_{hp} \quad K=3)$$

Deras form i Fourier domänen beror av $C(x)$

Ex)

$$C = \gamma_1 \hat{e}_1 \hat{e}_1^T + \gamma_2 \hat{e}_2 \hat{e}_2^T$$

$$\gamma_1 = \gamma_2 = 0 \quad \gamma_1 = \gamma_2 = 0,5 \quad \gamma_1 = 1 \quad \gamma_2 = 0$$

$$\text{Den förbättrade bilden blir } h = (f * g_{lp})(x) + \sum c_k (f * g_{hp})(x)$$

9. $L = |\nabla f| = \sqrt{f_x^2 + f_y^2} = ?$?

10. RANSAC = RANdom SAmple Consensus

1. Välj n punkter (randomly)
2. Uppskatta en modell utifrån dessa
3. Beräkna antalet punkter som följer modellen (antalet inliers)
baserat på ett maximalt tillåtet fel. Övriga är outliers.
4. Repetera tills en modell med tillräckligt många inliers
funnits eller välj bästa modellen av K iterationer.

I detta fall:

1. Välj 8 motsvarande punkter (för 8-punktsmodellen)
2. Beräkna en Fundamental matris F från punktparen.
3. Inliers uppfyller villkoret: $X_1^T F X_2 = 0$ Kolla alla punkter
i hela bilden och beräkna totala felet.
4. Repetera tills litet fel eller bäst av K iterationer.

11. Med homografier?

Affine transformation

$$\begin{pmatrix} a_{11} & a_{12} & t_1 \\ a_{21} & a_{22} & t_2 \\ 0 & 0 & 1 \end{pmatrix} \quad 6 \text{ dof}$$

Similarity transformation

$$\begin{pmatrix} s_1 & s_2 & t_1 \\ -s_2 & s_1 & t_2 \\ 0 & 0 & 1 \end{pmatrix} \quad 4 \text{ dof}$$

similarity + scale

skala, translation, rotation

12.

?