

Mars 2011 - Tracking

1. a) $P(I) = \sum_{k=1}^K P(I|\Gamma_k) P(\Gamma_k)$ $P(I)$ = sannolikhet för pixelintensitet I

$P(I|\Gamma_k)$ = sannolikhet för intensitet I givet fördelning Γ_k

$P(\Gamma_k)$ = sannolikhet för fördelning Γ_k , K = antal fördelningar

b) mean $\mu_k = \frac{\sum_{n=1}^N w_{kn} I_n}{\sum_{n=1}^N w_{kn}}$ standard deviation $\sigma_k^2 = \frac{\sum_{n=1}^N w_{kn} (I_n - \mu_k)^2}{\sum_{n=1}^N w_{kn}}$

2. a) Use regularized derivatives:

$$\frac{\partial}{\partial x} (f * g)(x) = (\frac{\partial f}{\partial x} * g)(x) = (f * \frac{\partial g}{\partial x})(x) = (f * \frac{-x}{\sigma^2} g)(x)$$

Derivatan av ett gaussiskt filter blir alltid $-x/\sigma^2$.

b) $I(x)$ is the first image and $J(x)$ the second image.

3. Using 1st order Taylor expansion:

$$f(x + \frac{1}{2}d) \approx f(x) + \frac{1}{2}d^T \nabla f(x), \quad g(x - \frac{1}{2}d) \approx g(x) - \frac{1}{2}d^T \nabla g(x)$$

Minimum av ϵ map. d då $\frac{\partial \epsilon}{\partial d} = 0$

$$\begin{aligned} \frac{\partial \epsilon}{\partial d} &= \frac{\partial}{\partial d} \left(\iint (f(x) + \frac{1}{2}d^T \nabla f(x) - g(x) + \frac{1}{2}d^T \nabla g(x))^2 w(x) dx \right) \\ &= 2 \iint (f(x) + \frac{1}{2}d^T \nabla f(x) - g(x) + \frac{1}{2}d^T \nabla g(x)) \left(\frac{1}{2} \nabla f(x) + \frac{1}{2} \nabla g(x) \right) w(x) dx \\ &= \iint (f(x) - g(x)) (\nabla f(x) + \nabla g(x)) w(x) dx + \frac{1}{2} \iint d^T (\nabla g(x) + \nabla f(x)) (\nabla f(x) + \nabla g(x)) w(x) dx \end{aligned}$$

$$\left(= e + \frac{1}{2} (T_1 + T_2) d \quad d = \frac{-2e}{T_1 + T_2} = -2(T_1 + T_2)^{-1} e \right)$$

$$- \iint (f(x) - g(x)) (\nabla f(x) + \nabla g(x)) w(x) dx$$

$$\Rightarrow d = 2 \frac{- \iint (\nabla g(x) + \nabla f(x)) \nabla f(x) w(x) dx}{\iint (\nabla g(x) + \nabla f(x)) \nabla f(x) w(x) dx}$$

$$d(T_1 + T_2) = e \quad (d = T^{-1} e)$$

$$T^{-1} d = T^{-1} e$$

Mars 2011 - Motion

4.

Lucas-Kanade

Block-matching

Beräkningsstunt

Nja

Ja

← hara
derivation

Kan hantera
differentierbara bilder

Nej

Ja

Man kan kombinera dem genom att först köra LS
och om man kommer till ett icke-differentierbart
område så kör man det längsammare BM bara där...?

5. a) $\frac{\partial f}{\partial x_1} = a \quad \frac{\partial f}{\partial x_2} = b \quad \frac{\partial f}{\partial t} = d \quad f = ax_1 + bx_2 + c$

$aV_1 + bV_2 + d = 0$ sen?

b) ?

6. a) 2D: least square minimization of $\xi = \int_{\Omega} w(x) (\nabla_{ST}^T \nabla_{ST} f)^2 dx$

$$V_{ST} = (V_x, V_y, 1) \quad V = T_{2D}^{-1} S$$

3D: total least square minimisation of $\xi = \int_{\Omega} w(x) (\nabla_{ST}^T V_{ST} f)^2 dx$

$$\nabla_{ST} = (r_1, r_2, r_3), \quad V_x = r_1/r_3, \quad V_y = r_2/r_3, \quad \|V_{ST}\| = 1$$

∇_{ST} är egenvektor till T_{3D} med minst egenvärde

b) Metod med T_{2D} får problem tyj T_{2D}^{-1} blir nära singulär
i områden som är i 1D.

Metod med T_{3D} upptäcker aperture problemet

Mars 2011 - Denoising

7. Regulariseringen kan göras med antagandet att D varierar långsamt med utseende på x . Varför rimligt?
 D baseras på T (samma egenvektorer men andra egenvärden)?

8. Control tensorn C har samma egenvektorer som T men andra egenvärden. Mapping enligt följande (givet Tx^*):

1. Lågpass filtrera $T(x)$ till $T_{lp}(x)$

2. Normalisera $T_{lp}(x)$, $\hat{T}_{lp} = \sum_{k=1}^n \lambda_k \hat{e}_k \hat{e}_k^T \quad \lambda_x \geq \lambda_{x+1}$

3. Sätt $c = \sum_{k=1}^n \gamma_k \hat{e}_k \hat{e}_k^T \quad \gamma_k = \gamma_k(\lambda_1, \dots, \lambda_n) \quad \gamma_n = e^{-\lambda_n/k}$

Okej, lite oklart i steg 3.

7. Varför rimligt?

D baseras på T som representerar derivator (gradienter).

Derivator ändras långsamt i verkligheten, förutom i diskontinuiteter. Därför är det ett rimligt antagande.

Mars 2011 Stereo

10. RANSAC general form:

- 1) Pick n points at random
- 2) Estimate a model from these points
- 3) Calculate #inliers and #outliers
- 4) Repeat until model with sufficient #inliers is found or choose best of k iterations

This case:

- 1) pick n points from each view (from iterative corres?)
- 2) if $y_1 \sim C_1 x$ and $y_2 \sim C_2 x$ is forefilled
 y_1 and y_2 are corresponding points
- 3) calculate #corresponding points = inliers - reprojection error
- 4) Repeat until enough correspondences are found tillräckligt litet

11. Geometric invariance: Rotation, scaling, skewing

Photometric invariance: Intensity scaling, intensity offset ($I = kI + k_0$)

Geometric invariances are useful to create robustness

to view changes and photometric invariance to
create robustness to illumination changes.

12. $e_{21} = C_2 P_1$ $e_{12} = C_1 P_2$ $F = [e_{12}]^+ C_1 C_2^+$. . . ?

a) -

b) Epipolar villkoret:

$$e_{12}^T F_{12} e_{21} = 0$$

$$e_{23}^T F_{23} e_{32} = 0$$

$$e_{31}^T F_{31} e_{13} = 0$$