

Juni 2012 - Tracking

1. a) Compute partial membership: $\tilde{w}_{kn} = P(I_n | \Gamma_k) P(\Gamma_k)$

$$w_n = \frac{\tilde{w}_{kn}}{\sum_{k=1}^N w_{kn}}$$

b) Update model parameters: $P(\Gamma_k) = \frac{1}{N} \sum_{n=1}^N w_{kn}$

$$\mu_k = \frac{\sum_{n=1}^N w_{kn} I_n}{\sum_{n=1}^N w_{kn}} \quad \sigma_k^2 = \frac{\sum_{n=1}^N w_{kn} (I_n - \mu_k)^2}{\sum_{n=1}^N w_{kn}}$$

2. w - weight to determine local region. Choose depending on image. For example a gaussian function or a box filter.

a - gradient of image a. Calculate using derivative filters or (preferably) regularised derivative.

b - b is an image, it is given, already known.

3. a) $\epsilon = \sum \|f_1(x - \frac{1}{2}d) - f_2(x + \frac{1}{2}d)\|^2$

b) Taylor expansion 1D case:

$$f_1(x - \frac{1}{2}d) \sim f_1(x) - \frac{1}{2}d f'_1(x) \quad f_2(x + \frac{1}{2}d) \sim f_2(x) + \frac{1}{2}d f'_2(x)$$

$$\epsilon = \sum \|f_1(x) - \frac{1}{2}d f'_1(x) - f_2(x) - \frac{1}{2}d f'_2(x)\|^2$$

$$\frac{d\epsilon}{da} = 2 \sum (f_1(x) - f_2(x) - \frac{1}{2}d(f_1'(x) + f_2'(x))) \cdot \frac{1}{2}(f_1'(x) + f_2'(x))$$

$$\frac{d\epsilon}{da} = \sum (f_1(x) - f_2(x))(f_1'(x) + f_2'(x)) - \frac{d}{2} \sum (f_1'(x) + f_2'(x))^2 = 0$$

$$d = 2 \frac{\sum (f_1(x) - f_2(x))(f_1'(x) + f_2'(x))}{\sum (f_1'(x) + f_2'(x))^2}$$

(Jämfört med Task 2 är tilljären e och hämparen m)

Juni 2012 - Motion

4. a) Coarse-to-fine is used to get a faster algorithm.

Ett tillfälle när man vill använda det kan vara när man tror att objektet fört sig långt.

b) $J(x) = g * I(2,0x - 0,5)$ Transform $x_I = 2x_J - 0,5$

$$x_J = \frac{x_I + 0,5}{2} \quad \text{Dvs vi hittar vektor på plats}$$

$\frac{x_I + 0,5}{2}$. Resultatet ska skalias med 2.

5 1) $V_{st} = (V_1, V_2, 1)$ dvs V i homogena koordinater

$V_{st} = T_{2D}^{-1} e$ efter least square minimisation of ϵ .

2) $\|\hat{V}_{st}\| = 1 \quad \hat{V}_{st} = (n, r_2, r_3), \quad n = \frac{r_1}{\sqrt{r_2^2 + r_3^2}} \quad T_{3D} \hat{V}_{st} = \lambda \hat{V}_{st}$

V_{st} är den egenvektor

till T_{3D} med minst egenvärde.

Metod 2 är mer räknelätt eftersom en 3D-tensors används.

Metod 1 klarar inte av 3D-regimer eftersom T_{2D} blir

singulär (eller nära singulär). Metod 2 kan dock
upptäcka aperture problemet.

6. a) $L = \int (V(x_1, x_2) \nabla_{2D} f + \frac{df}{dt})^2 dx + \beta \int \|\nabla_{2D} V_1\|^2 + \|\nabla_{2D} V_2\|^2 dx$

Assumption: Kontinuitigt, "smoothly varying" V V =motion field

b) Antagandet gäller inte vid "occlusion" eftersom

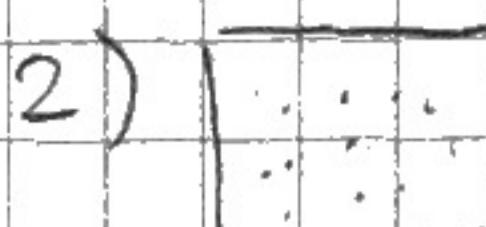
det är ett typiskt fall där det ska bli en skarp
kant i rörelsefältet (motion field V)

Juni 2012 - Denoising

7. Bilderna



mycket struktur



lite struktur

a) Perona-Malik (= inhomogeneous diffusion)



1) Liten symmetrisk kärna

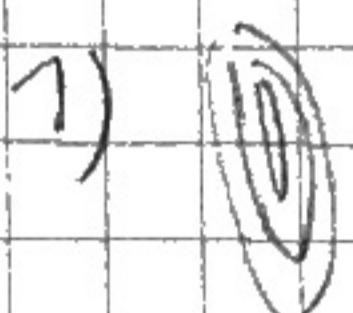
(small support)



2) Stor symmetrisk kärna

(large support)

b) Tensor-driiven (= anisotropic diffusion)



1) Elliptisk filterkärna

smoothar längs strukturen



2) Cirkulär filterkärna

smoothar lika mycket öradit

Bruksnivån efter filtrering:

1 a) Lite reducerad bruksnivå

1 b) Ganska reducerad bruksnivå

2 a) Mycket reducerad bruksnivå

2 b) Ganska reducerad bruksnivå

$$g_x = g_{lp} + \sum_{k=1}^K c_k g_{hp,k} \quad (K=3 \text{ för 2D-bild})$$

g_{lp} = lågpass filter för att behålla medelintensiteten

g_{hp} = beror av lokal struktur, radiell funktion, ska bevara linjer och kanter

$$c_k = \langle T(x) | \tilde{N}_i \rangle$$

$$b) h = f * g_{lp} + \sum_{i=1}^N \langle T(x) | \tilde{N}_i \rangle f * g_{hp,i} \quad N=3 \text{ för 2D-bild}$$

pixelberende konstant (skalär)

Dvs färlning med lp och hp filter och bilden
och en linjärkombination av hp-filtren med
koeficienterna i c_k .

9. a) $L = |\nabla f| = \sqrt{f_x^2 + f_y^2}$

b) $-\operatorname{div} \left(\frac{\nabla f}{|\nabla f|} \right) = 0$

c) Problem när $|\nabla f|=0$ ty division med noll.

Kan hanteras genom att sätta termen till

$$-\operatorname{div} \left(\frac{\nabla f}{|\nabla f| + \epsilon} \right) \text{ där } \epsilon \text{ är en liten konstant.}$$

d) 1D-signal \rightarrow medianfilter

Juni 2012 - Multiple View Geometry

10. a) $P = \text{outlier}$ $(1-P) = \text{inlier}$ $\underline{(1-P)^4 = 4 \text{ inliers}}$
- b) Vilken som hänt från A, chansen att den man har i B är en correspondance är $1/100 = 0,01$
11. a) Rotation is in SIFT found from a gradient histogram. (Translation and scale from difference of Gaussians pyramid.)
- b) Affine illumination invariance in SIFT by using gradients and normalising $\hat{h} = h/\|h\|$
(Generellt affine photometric invariance $\hat{I} = (I - \mu)/\sigma_s$)
12. a) Perspective-n-point problem, solve a non-linear minimisation problem. Minimize $\epsilon = d_1^2 + d_2^2 + d_3^2$.
där d_i är avståndet mellan återprojektionen av 3D-punkten och 2D-punkten i bilden.
Givet: 3D-punkter i två views, correspondanter, pos Kamera 1
Sökt: R och t, dis positioner för kamera 2
- b) $n=3$
- c) I en 3D-rekonstruktions pipeline kan PnP användas för att hitta korrekt position för kameran varje gång en ny view läggs till.
- Skillsnaden från BA är att BA optimiseras mot projektionsfelet genom att flytta både kamerornas position och 3D-punkterna. BA kan göras över flera kamrar eller över alla.